

Evo-0: 具备隐含空间理解的视觉-语言-动作模型

Tao Lin*, Gen Li*, Yilei Zhong, Yanwen Zou, Bo Zhao†

¹School of AI, Shanghai Jiao Tong University, ²EvoMind Tech, ³IAAR-Shanghai
taolin200108@gmail.com, bo.zhao@sjtu.edu.cn
<https://github.com/MINT-SJTU/Evo-VLA>

Abstract

视觉-语言-动作 (VLA) 模型已成为一种极具潜力的框架,旨在赋予通用机器人感知、推理及在现实世界中行动的能力。这些模型通常基于预训练的视觉-语言模型 (VLMs),后者因大规模文本预训练而在语义理解上表现出色。然而,VLMs 普遍缺乏精确的空间理解能力,因为它们主要针对二维图文对进行调优,缺乏三维监督。

为克服这一局限,近期研究引入了如点云或深度图等显式三维输入,但这需要额外的深度传感器或存在缺陷的估计方法。相比之下,我们的工作提出了一种即插即用模块,通过利用现成的视觉几何基础模型,将三维几何特征隐式注入 VLA 模型中。

我们设计了五项空间挑战任务,要求具备精确的空间理解能力,以验证方法的有效性。广泛的评估表明,我们的方法在多种场景下显著提升了最先进 VLA 模型的性能。

设计了五项测试空间理解能力的任务,

途径一: 点云或深度图显示输入
途径二: 将三维几何特征隐式注入VLA模块中

1 引言

视觉-语言-动作 (VLA) 模型近来引起了广泛关注并取得了显著进展。这些模型通常利用机器人操作数据对预训练的视觉-语言模型 (VLMs) 进行微调,以发挥从大规模图文数据中学成的视觉-语言泛化能力。这一范式在众多现实世界及模拟任务中均取得了令人瞩目的成果。

然而,现有的 VLA 模型存在一个致命的局限性,即缺乏精确的三维空间理解。这一缺陷主要归因于两个因素:(1) VLM 的预训练数据和目标主要基于二维图像-文本对齐,以及(2) 用于微调的机器人数据集通常规模较小,且仅包含 RGB 观测数据,缺乏明确的三维空间信息。因此,这些模型往往难以捕捉精确的几何和空间关系,而这些关系对于在物理世界中进行有效交互至关重要。最近的研究 Cai et al. (2024); Daxberger et al. (2025) 已经通过实验验证了这一观察结果,表明 VLM 在仅从视觉输入解释三维结构时往往泛化能力较差。这为将 VLA 模型扩展到更复杂的任务和物理基础场景带来了关键的瓶颈。

VLM缺乏三维空间理解

为了解决这一局限性,新兴方法 Li et al. (2025a); Qu et al. (2025); Zhen et al. (2024); Li et al. (2025b) 尝试将 3D 信息融入 VLA 模型,以增强其空间理解能力。一种常见策略是明确地将深度信息注入学习流水线,例如通过深度传感器捕获或由深度估计网络 Cai et al. (2024); Bhat et al. (2023); Yang et al. (2024) 预测的点云或深度图。尽管这些方法在一定程度上有效,但它们也带来了新的挑战。这些方法通常需要额外的深度传感器,而在实际情景中可能并不具备。此外,有缺陷的深度估计可能会引入额外的噪声,影响学成 3D 表示的可靠性。

预测的点云或深度图本来就存在噪音!

*Equal contribution †Corresponding author

本文介绍了 Evo-0, 一种新颖的 VLA 架构, 探索了一种替代策略, 以隐式方式增强 VLA 模型的空间理解能力。具体而言, 我们利用了视觉几何基础 Transformer (VGGT) Wang et al. (2025) 的强大 3D 感知能力, 该模型在大规模 2D-3D 配对数据集上训练。这些 3D 特征可以从机器人数据的原始视频输入中通过 VGGT 获取, 无需依赖显式深度输入或估计, 即可补充 VLMs。为此, 我们设计了一个轻量级融合模块, 将 VGGT 的几何基础特征与 VLM 中的视觉 token 集成, 使模型能够更有效地感知物体布局并推理空间关系。我们通过在五个空间挑战性现实任务上的全面实验, 展示了我们方法的有效性, 我们的模型在空间理解方面持续提升, 并超越了最先进的 VLA 模型。

总结而言, 我们在本工作中做出了两大主要贡献: (1) 提出了一种即插即用模块, 通过从视觉几何基础 Transformer (VGGT) 隐式注入 3D 几何先验, 增强 VLA 模型的空间理解能力; (2) 设计并评估了我们的方法在五项多样化且空间挑战性任务上的表现, 相较于强基准模型, 展示了持续的性能提升。

2 相关工作

视觉-语言-动作模型。最近, 多项研究 Kim et al. (2024); Black et al. (2024); Bjorck et al. (2025); Li et al. (2025b); Liu et al. (2024); Brohan et al. (2023) 致力于通过扩展预训练的视觉-语言模型 (VLMs) 来构建通用机器人策略, 赋予其动作预测能力。这些被称为视觉-语言-动作 (VLA) 的模型, 在广泛的具身任务中展现出强大的性能和 few-shot 泛化能力。

其中, OpenVLA Kim et al. (2024) 在来自 Open-X Embodiment O’Neill et al. (2024) 数据集的 970k 多机器人演示上进行训练, 展示了在广泛任务和实现中的强大泛化能力, 并支持在有限计算资源下的高效微调。 π_0 Black et al. (2024) 将 PaliGemma Beyer et al. (2024) 架构应用于机器人控制, 并引入了一个基于流匹配 Lipman et al. (2022); Liu (2022) 的动作专家模块, 能够准确预测连续动作。GR00T Bjorck et al. (2025) 提出了一种有效的协同训练策略, 在统一框架内联合利用网络数据、合成数据和真实世界机器人数据, 实现了跨任务和实现的广泛泛化。

尽管取得了令人瞩目的进展, 但现有的大多数 VLA 模型主要依赖二维视觉输入, 并缺乏有效机制来建模场景的三维空间结构, 这限制了它们在复杂操作任务中的空间推理能力。

机器人学习与三维信息。针对基于二维的 VLA 模型在空间上的局限性, 近期的一些方法 Cai et al. (2024); Zhen et al. (2024); Li et al. (2025a); Qu et al. (2025); Chen et al. (2024); Goyal et al. (2024); Jia et al. (2024) 探索了整合三维信息以增强空间理解。例如, 3D-VLA Zhen et al. (2024) 通过一个基于三维的大型语言模型 Hong et al. (2023) 融合了三维感知、推理和动作, 该模型在从现有具身机器人基准中整理的大规模三维数据集上进行训练。为了使三维感知策略适用于现实世界场景, 诸如 SpatialVLA Qu et al. (2025) 和 PointVLA Li et al. (2025a) 等方法结合了从额外 RGB-D 摄像头或深度估计模型获取的深度信息, 这增强了三维场景理解, 并实现了对空间关系、物体几何形状及深度感知交互的更准确感知。

尽管取得了这些进展, 当前 3D 感知 VLA 方法的一个根本局限在于其对深度图和点云等显式 3D 输入的依赖, 这些输入需要专门的传感器或辅助估计模型。这种依赖对可扩展性、部署灵活性以及在多样化现实环境中的普遍适用性构成了约束。

为解决这一问题, 我们提出将 VGGT Wang et al. (2025) 集成到现有的 VLA 模型中。在保持输入为 RGB 图像的同时, VGGT 通过融合多视角观测的空间特征, 隐式地建模 3D 结构。我们的方法在纯 2D 输入模型与显式 3D 感知方法之间架起桥梁, 无需额外传感器或深度估计模块即可增强空间理解能力。

以前方法增加了VLA对额外深度图和点云的依赖

失去了普适性

3 方法

3.1 初步研究

视觉-语言-动作模型。作为一种有望实现通用机器人策略的方法，视觉-语言-动作（VLA）模型已成为日益流行的研究方向 Black et al. (2024); Kim et al. (2024); Li et al. (2025a); Liu et al. (2025)。VLA 旨在通过利用大规模预训练视觉-语言模型（VLMs）中编码的丰富多模态先验，弥合高级人类指令与低级机器人动作之间的差距，例如 Paligemma Beyer et al. (2024)、CLIP Radford et al. (2021)、LLaMA Touvron et al. (2023a;b) 和 Flamingo Alayrac et al. (2022)。这些 VLMs 在大量多样的互联网级图像-文本对上进行训练，使其具备强大的世界知识，并能够将自然语言与视觉概念相结合。

与传统的模仿学习方法通常从零开始训练特定任务的策略不同，VLA 模型复用这种预训练的多模态理解能力，以实现更灵活和可扩展的机器人行为。具体而言，VLM 充当通用语义编码器，而下游模块——通常称为动作专家——学习将融合的表达映射为机器人控制命令。这种模块化设计将通用的世界理解与特定任务的动作分离开来，使得模型能够更好地泛化于不同指令和视觉环境。

在每个时间步 t 上，VLA 模型接收多视角视觉观测 $\{I_t^i\}_{i=1}^N$ 和语言指令 L ，它们通过 VLM 联合编码生成上下文嵌入 z_t 。该嵌入随后与机器人特定状态 S_t （例如，关节角度、夹爪状态或末端执行器姿态）连结，并传递给动作专家以生成低级控制命令 A_t 。整个流水线因此定义了一个条件分布 $p(A_t | I_t^i, L, S_t)$ 。

与通常针对特定任务训练的标准模仿学习策略相比，VLA 框架提升了语义基础、模态融合和泛化能力。这使得机器人不仅能够遵循多样且抽象的语言指令，还能以最少的微调适应新任务和视觉场景。

视觉几何基础模型。与依赖精细调校模块和传感器的传统 SLAM 或深度估计流水线不同，视觉几何基础模型（VGFM）Leroy et al. (2024); Wang et al. (2024; 2025); Li et al. (2025c) 是一类经过训练以从二维视觉输入重建三维结构信息的视觉模型。由于 VGFM 在几何监督下训练，它们能够从多视角单目输入中恢复细粒度的空间结构。这些模型为下游任务（如空间理解）**提供了强大的结构先验**，尤其是在**无法使用显式三维传感器的情况下**。

给定一组多视角图像 $\{I^i\}_{i=1}^N$ ，典型的 VGFM 会预测一个表示场景的 3D 点云 P 。

$$f_{\text{VGFM}}(\{I^i\}_{i=1}^N) = P. \quad (1)$$

这些几何感知模型通过融入三维结构线索，增强了仅基于二维观察（如视频帧）的空间定位能力，从而与视觉-语言系统形成互补。

最近，视觉几何接地 Transformer（VGGT）Wang et al. (2025) 引入了一种新颖的前馈架构，并在 3D 属性预测中展示了出色的表现。它以任意数量的图像视图作为输入，并在帧级和全局自注意力之间交替，以建模空间一致性。给定一个序列的 N RGB 图像 $\{I^i\}_{i=1}^N$ ，其中每个 $I_i \in \mathbb{R}^{3 \times H \times W}$ ，该模型为每一帧输出一组 3D 标注，包括预测的相机姿态 g_i 、深度图 D_i 、点图 P_i 和 3D 点轨迹 T_i ，即

$$f(\{I_i\}_{i=1}^N) = (g_i, D_i, P_i, T_i)_{i=1}^N. \quad (2)$$

3.2 提议的 VLA 架构

最近的 3D 基础 VLA 模型，如 PointVLA Li et al. (2025a) 和 SpatialVLA Qu et al. (2025)，常采用点云或深度图等显式 3D 输入来增强空间理解。虽然有效，这些方法通常需要额外传




图 1: Evo-0 的架构

VGGT用在VLM架构上

传感器和预处理，且对相机视角变化较为敏感。相比之下，VGGT 提供了一种有前景的替代方案，通过其多样化的训练数据和简洁的前馈架构，**隐式引入空间感知**。近期研究已成功将 VGGT 应用于 VLM 架构 Wu et al. (2025) 和 SLAM 系统 Maggio et al. (2025)，**表明基于几何的视觉 token 能在多模态学习和经典机器人感知中提升空间理解能力**。

基于这些发现，我们假设将 VGGT 中的几何感知视觉表示引入动作预测流水线可以丰富空间上下文，从而在不需显式点云或深度输入的情况下，实现更精确且可泛化的策略学习。为了验证这一假设，我们在最先进的开源 VLA 模型 $\pi 0$ Black et al. (2024) 的基础上构建了我们的模型，并将 VGGT 的几何感知特征整合到其视觉嵌入流中。该架构如图 1 所示。具体而言，我们利用 VGGT 作为空间编码器，并从其最后一层提取 token。

$$\mathcal{E}_l(\{I_i\}_{i=1}^N) = t_c, t_r, t_{3D}, \quad (3)$$

其中 N 是视图数量， l 表示层索引， t_c 、 t_r 和 t_{3D} 分别表示相机、寄存器和 3D token。我们提取 3D token t_{3D} 以注入空间信息，因为它们最初被训练用于在 VGGT 中执行 3D 任务。这些 token 捕捉了丰富的几何表示，包括深度感知上下文、时间一致的对象轨迹以及跨视图的空间对应关系。

为了将 VGGT 衍生的 token 特征整合到视觉-语言流水线中，我们引入了一个轻量级的融合模块，该模块结合了来自 Vision Transformer Dosovitskiy et al. (2020) 和 VGGT 编码器的嵌入。具体而言，融合器由一个单一的交叉注意力层组成，其中 2D 视觉 token $t_{2D} \in \mathbb{R}^{N \times M_{2D} \times d_{2D}}$ 作为查询，而 VGGT 衍生的 token $t_{3D} \in \mathbb{R}^{N \times M_{3D} \times d_{3D}}$ 作为键和值。这里， M_{2D} 和 M_{3D} 分别表示来自 ViT 和 VGGT 编码器的 token 数量。随后，2D 视觉 token 按如下方式更新：

$$Q = t_{2D}W_Q, \quad K = t_{3D}W_K, \quad V = t_{3D}W_V, \quad (4)$$

$$t^i = \text{softmax}\left(\frac{Q^i(K^i)^\top}{\sqrt{d}}\right)V^i, \quad (5)$$

$$t = \text{Concat}_{i=1}^N(t^i), \quad (6)$$

交叉注意力模块




图 2: 任务设置示意图。

其中 $W_Q \in \mathbb{R}^{d_{2D} \times d}$, 以及 W_K 、 W_V 和 $\in \mathbb{R}^{d_{3D} \times d}$ 是跨视图共享的可训练投影矩阵。每个视图 $i \in 1, \dots, N$ 通过交叉注意力模块独立处理, 处理后的 token 被连结起来形成融合输出 t 。

融合后的 token 随后被传递到 PaliGemma Beyer et al. (2024) 视觉-语言模型中, 该模型同时对几何增强的视觉输入和语言 token 进行联合注意力处理, 以预测动作。为了保持计算效率并最小化对预训练 VLM 主干的干扰, 我们冻结了核心 VLM 参数, 并插入了轻量级的低秩适应 (LoRA) Hu et al. (2022) 层。在训练过程中, 仅对融合模块、LoRA 层和流匹配动作专家进行微调, 从而实现以最小开销进行有效适应。

4 实验

4.1 实现细节

我们的框架基于开源的 VLA 模型 Black et al. (2024)。对于每个任务, 我们通过远程操作收集了 100 个专家示范。为了促进多样性和鲁棒性, 在数据采集过程中, 物体和目标的位置被随机扰动。模型使用 AdamW 进行训练, 权重衰减为 10^{-10} 。采用余弦学习率调度, 学习率为 2.5×10^{-5} , 预热 1000 步, 并衰减至 2.5×10^{-6} 。训练在单个 NVIDIA A800 GPU (80GB) 上使用 bfloat16 混合精度进行, 批量大小为 32。

4.2 任务设置

我们设计了五项现实世界机器人评估任务, 这些任务涵盖了从精细几何对接到抓取放置及透明物体交互等一系列空间理解挑战。特别地, 每项任务对空间误差的容差要求极低, 因为空间预测中的微小偏差都可能导致任务失败。这使它们非常适合用于评估 VGGT 的表示是否能增强 VLA 的空间理解能力。

下面提供了五项任务的详细描述, 具体图示见 Figure 2。

1. **将圆柱体对准目标中心。** 机器人需要将一个圆柱体精确对齐到桌面上标记的目标区域中心。此任务类似于射击: 目标由同心圆环组成, 得分基于圆柱体中心落入哪个圆环。越接近中心, 得分越高。
2. **插销入孔任务。** 该任务要求机器人将圆柱形销钉插入板上三个紧密配合的孔之一。这需要在三维空间中进行精确对准, 因为轻微的倾斜或偏移都可能导致任务失败。
3. **中间瓶子抓取。** 三个瓶子紧密排列成一行, 机器人被指示抓取中间的瓶子。这一设置模拟了杂货店场景, 其中物品在货架上稠密摆放。成功的定义是抓取中间瓶子而不触碰或碰倒相邻的瓶子。
4. **能够进行拾取和放置。** 在此任务中, 机器人必须拾取一个标准罐子并将其放置在货架上的指定位置。放置的位置在试验中会发生变化, 包括位置和高度, 要求模型能够将空间理解泛化到不同的配置中。




图 3: 我们模型在现实任务中的定性成果。

	Task1 (15)	Task2 (15)	Task3 (15)	Task4 (10)	Task5 (20)	Average (75)
π_0	59.33%	20.00%	13.30%	20.00%	30.00%	28.53%
Ours	68.67%	66.67%	26.70%	60.00%	65.00%	57.41%

表 1: 五项现实任务的成功率。括号中的数字表示每项任务的试验次数。特别地，任务 1 通过得分进行评估；例如，68.67% 表示我们的模型在满分 5 分中平均获得 3.43 分。

5. **透明物体的抓取与放置。**任务设置与之前类似，但涉及透明物体，如玻璃瓶。这带来了额外的挑战，因为透明材料通常难以被 RGB 传感器准确捕捉，且容易产生反光，使得它们难以被感知和定位。

除任务一外，我们均采用二元任务完成度对所有任务进行评估。针对任务一，我们借鉴了射击靶标的精细评价方法：最内环赋予最高得分（5 分），外环则对应递减的准确率（4 至 1 分）。若机器人未能抓取物体，则得分为 0。此评分体系捕捉了空间精确度上的细微差异，这些差异在二元度量中会丢失。我们报告了每项任务的整体成功率（或任务一的平均得分）。为确保公平比较与可复现性，物体位置通过贴纸标记。

4.3 现实世界实验

定量结果。我们通过将所提方法与基准模型 π_0 进行比较来评估其有效性。定量结果如表 1 所示。在所有任务中，我们的方法相较于基准均取得了稳定的提升，表明隐含的 3D 几何特

征对任务性能有积极贡献。值得注意的是，我们的模型在任务 2（插销入孔）上表现出最大的性能提升，这是一个特别具有挑战性的任务，需要精确的空间推理能力。此外，任务 3（中间瓶子抓取）由于相邻瓶子之间的狭窄间隙，对夹爪提出了严峻挑战，要求其进行谨慎、无碰撞的插入与抓取。与基准相比，我们的方法在此任务上展现了合理的改进，证明了在复杂环境中增强的空间理解与控制能力。总体而言，我们在平均成功率上实现了 28.88% 的性能提升。

定性结果。在图 3 中，我们展示了不同任务执行的可视化结果。这些视觉结果进一步补充了定量发现，展示了我们模型在空间感知和操作准确率方面的提升。例如，在圆柱体居中和孔内插销任务中，我们的模型能够可靠地实现稳定抓取并与目标区域精确对齐。相比之下，基准 π_0 通常无法从初始步骤开始正确抓取圆柱体，导致放置尝试失败或不稳定。

5 结论

本文探讨了利用**隐式三维**表示来增强视觉-语言-动作（VLA）模型的空间理解能力。通过引入基于大规模二维-三维配对数据训练的视觉几何基础 Transformer（VG GT）的特征，我们在不依赖显式三维输入的情况下，向 VLA 模型注入了强大的几何先验。在五项空间挑战性任务上的广泛实验表明，该方法显著超越了基准模型，验证了所提出的隐式几何先验集成的有效性。我们的方法为提升 VLA 系统的空间理解提供了一种简单而高效的解决方案。

参考文献

- Jean-Baptiste Alayrac, Jeff Donahue, Pauline Luc, Antoine Miech, Iain Barr, Yana Hasson, Karel Lenc, Arthur Mensch, Katie Millican, Malcolm Reynolds, Roman Ring, Eliza Rutherford, Serkan Cabi, Tengda Han, Zhitao Gong, Sina Samangooei, Marianne Monteiro, Jacob Menick, Sebastian Borgeaud, Andrew Brock, Aida Nematzadeh, Sahand Sharifzadeh, Mikolaj Binkowski, Ricardo Barreira, Oriol Vinyals, Andrew Zisserman, and Karen Simonyan. Flamingo: a visual language model for few-shot learning, 2022. URL <https://arxiv.org/abs/2204.14198>.
- Lucas Beyer, Andreas Steiner, André Susano Pinto, Alexander Kolesnikov, Xiao Wang, Daniel Salz, Maxim Neumann, Ibrahim Alabdulmohsin, Michael Tschanen, Emanuele Bugliarello, et al. Paligemma: A versatile 3b vlm for transfer. arXiv preprint arXiv:2407.07726, 2024.
- Shariq Farooq Bhat, Reiner Birkel, Diana Wofk, Peter Wonka, and Matthias Müller. Zoedepth: Zero-shot transfer by combining relative and metric depth. arXiv preprint arXiv:2302.12288, 2023.
- Johan Bjorck, Fernando Castañeda, Nikita Cherniadev, Xingye Da, Runyu Ding, Linxi Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, et al. Gr00t n1: An open foundation model for generalist humanoid robots. arXiv preprint arXiv:2503.14734, 2025.
- Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. π_0 : A vision-language-action flow model for general robot control, 2024. URL <https://arxiv.org/abs/2410.24164>, 2024.

- Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. arXiv preprint arXiv:2307.15818, 2023.
- Wenxiao Cai, Yaroslav Ponomarenko, Jianhao Yuan, Xiaoqi Li, Wankou Yang, Hao Dong, and Bo Zhao. Spatialbot: Precise spatial understanding with vision language models. arXiv preprint arXiv:2406.13642, 2024.
- Shizhe Chen, Ricardo Garcia, Ivan Laptev, and Cordelia Schmid. Sugar: Pre-training 3d visual representations for robotics. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 18049–18060, 2024.
- Erik Daxberger, Nina Wenzel, David Griffiths, Haiming Gang, Justin Lazarow, Gefen Kohavi, Kai Kang, Marcin Eichner, Yinfei Yang, Afshin Dehghan, et al. Mm-spatial: Exploring 3d spatial understanding in multimodal llms. arXiv preprint arXiv:2503.13111, 2025.
- Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, et al. An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929, 2020.
- Ankit Goyal, Valts Blukis, Jie Xu, Yijie Guo, Yu-Wei Chao, and Dieter Fox. Rvt-2: Learning precise manipulation from few demonstrations. arXiv preprint arXiv:2406.08545, 2024.
- Yining Hong, Haoyu Zhen, Peihao Chen, Shuhong Zheng, Yilun Du, Zhenfang Chen, and Chuang Gan. 3d-llm: Injecting the 3d world into large language models. Advances in Neural Information Processing Systems, 36:20482–20494, 2023.
- Edward J Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, Weizhu Chen, et al. Lora: Low-rank adaptation of large language models. ICLR, 1(2):3, 2022.
- Yueru Jia, Jiaming Liu, Sixiang Chen, Chenyang Gu, Zhilue Wang, Longzan Luo, Lily Lee, Pengwei Wang, Zhongyuan Wang, Renrui Zhang, et al. Lift3d foundation policy: Lifting 2d large-scale pretrained models for robust 3d robotic manipulation. arXiv preprint arXiv:2411.18623, 2024.
- Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, et al. Openvla: An open-source vision-language-action model. arXiv preprint arXiv:2406.09246, 2024.
- Vincent Leroy, Yohann Cabon, and Jérôme Revaud. Grounding image matching in 3d with mast3r. In European Conference on Computer Vision, pp. 71–91. Springer, 2024.
- Chengmeng Li, Junjie Wen, Yan Peng, Yaxin Peng, Feifei Feng, and Yichen Zhu. Pointvla: Injecting the 3d world into vision-language-action models. arXiv preprint arXiv:2503.07511, 2025a.

- Peiyan Li, Yixiang Chen, Hongtao Wu, Xiao Ma, Xiangnan Wu, Yan Huang, Liang Wang, Tao Kong, and Tieniu Tan. Bridgevla: Input-output alignment for efficient 3d manipulation learning with vision-language models. arXiv preprint arXiv:2506.07961, 2025b.
- Zhengqi Li, Richard Tucker, Forrester Cole, Qianqian Wang, Linyi Jin, Vickie Ye, Angjoo Kanazawa, Aleksander Holynski, and Noah Snavely. Megasam: Accurate, fast and robust structure and motion from casual dynamic videos. In Proceedings of the Computer Vision and Pattern Recognition Conference, pp. 10486–10496, 2025c.
- Yaron Lipman, Ricky TQ Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. arXiv preprint arXiv:2210.02747, 2022.
- Jiaming Liu, Hao Chen, Pengju An, Zhuoyang Liu, Renrui Zhang, Chenyang Gu, Xiaoqi Li, Ziyu Guo, Sixiang Chen, Mengzhen Liu, et al. Hybridvla: Collaborative diffusion and autoregression in a unified vision-language-action model. arXiv preprint arXiv:2503.10631, 2025.
- Qiang Liu. Rectified flow: A marginal preserving approach to optimal transport. arXiv preprint arXiv:2209.14577, 2022.
- Songming Liu, Lingxuan Wu, Bangguo Li, Hengkai Tan, Huayu Chen, Zhengyi Wang, Ke Xu, Hang Su, and Jun Zhu. Rdt-1b: a diffusion foundation model for bimanual manipulation. arXiv preprint arXiv:2410.07864, 2024.
- Dominic Maggio, Hyungtae Lim, and Luca Carlone. Vggt-slam: Dense rgb slam optimized on the $sl(4)$ manifold, 2025. URL <https://arxiv.org/abs/2505.12549>.
- Abby O’Neill, Abdul Rehman, Abhiram Maddukuri, Abhishek Gupta, Abhishek Padalkar, Abraham Lee, Acorn Pooley, Agrim Gupta, Ajay Mandlekar, Ajinkya Jain, et al. Open x-embodiment: Robotic learning datasets and rt-x models: Open x-embodiment collaboration 0. In 2024 IEEE International Conference on Robotics and Automation (ICRA), pp. 6892–6903. IEEE, 2024.
- Delin Qu, Haoming Song, Qizhi Chen, Yuanqi Yao, Xinyi Ye, Yan Ding, Zhigang Wang, JiaYuan Gu, Bin Zhao, Dong Wang, et al. Spatialvla: Exploring spatial representations for visual-language-action model. arXiv preprint arXiv:2501.15830, 2025.
- Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision, 2021. URL <https://arxiv.org/abs/2103.00020>.
- Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, et al. Llama: Open and efficient foundation language models. arXiv preprint arXiv:2302.13971, 2023a.
- Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bashlykov, Soumya Batra, Prajjwal Bhargava, Shruti Bhosale, et al. Llama 2: Open foundation and fine-tuned chat models. arXiv preprint arXiv:2307.09288, 2023b.

- Jianyuan Wang, Minghao Chen, Nikita Karaev, Andrea Vedaldi, Christian Rupprecht, and David Novotny. Vggg: Visual geometry grounded transformer. In Proceedings of the Computer Vision and Pattern Recognition Conference, pp. 5294–5306, 2025.
- Shuzhe Wang, Vincent Leroy, Yohann Cabon, Boris Chidlovskii, and Jerome Revaud. Dust3r: Geometric 3d vision made easy. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 20697–20709, 2024.
- Diankun Wu, Fangfu Liu, Yi-Hsin Hung, and Yueqi Duan. Spatial-mlm: Boosting mllm capabilities in visual-based spatial intelligence, 2025. URL <https://arxiv.org/abs/2505.23747>.
- Lihe Yang, Bingyi Kang, Zilong Huang, Xiaogang Xu, Jiashi Feng, and Hengshuang Zhao. Depth anything: Unleashing the power of large-scale unlabeled data. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 10371–10381, 2024.
- Haoyu Zhen, Xiaowen Qiu, Peihao Chen, Jincheng Yang, Xin Yan, Yilun Du, Yining Hong, and Chuang Gan. 3d-vla: A 3d vision-language-action generative world model. arXiv preprint arXiv:2403.09631, 2024.